goorm AI 기술 자연어 처리 전문가 양성 과정 6 기 8 회차

첫 번째 프로젝트 . Yelp 식당 리뷰 데이터 를 활용한

문장 분류기 성능 개선

Team 2. GNLP
(Good Night after Last Project)
김도연 , 양은지 , 오희주 , 이다원 , 이지수 , 전효택 , 정명찬

CONTENTS

1. 프로젝트 개요

프로젝트 주제	**Yelp 식당 리뷰 데이터 를 활용한 문장 분류기 성능 개선**
개발 환경	**Python(Colab, VScode)** **Pytorch, Transformers, Wandb, Matplotlib**
진행 프로세스	**데이터 전처리 > 모델 선정 > Hyperparameter 최적화 > 앙상블 적용 성능 개선 > 최종 평가 , 모델 활용**
목표	**성능 개선 : 98.1% (baseline code) > 99%**

1. 프로젝트 개요

프로젝트 개요

1) 프로젝트 구현 내용

- yelp dataset 을 positive, negative 으로 분류
- Text classification task
- Baseline code 기반으로 다양한 model, hyper parameter tuning, ensemble 등 다양한 기법을 사용해서 Kaggle competition 에서 최적의 성능 (accuracy) 을 낸다 .
- 최종 정확도 99% 로 버그만 해결한 코드의 정확도 98.1 에서 0.9% 의 성능향상을 이뤄냈다 . 4 개팀 중 1 위와 0.1% 차이로 2 위를 차지했다 .

2) 프로젝트 개발 환경

- Colab Pro Plus 에서 GPU 를 이용했다 .
- GIT 으로 형상관리 및 팀원들과 원활한 코드 및 데이터 공유를 하였다 .
- Pytorch 를 이용하여 Train, Evaluation, Test 코드를 작성했다 .
- Wandb 를 활용하여 최적의 hyper parameter 를 찾아냈다 .
- Matplotlib 을 활용하여 iteration 에 따른 loss, accuracy 변화를 보고 각 모델간 성능 비교를 하였다 .
- Pandas 를 활용하여 csv 파일을 입력받아 df 의 여러 메소드를 활용하여 ensemble 의 기법인 hard voting 을 구현하였다 .

2. 팀 구성 및 역할

팀장

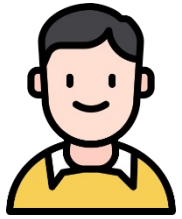

김도연
- 진행 사항 총 정리
- 데이터 정제 및 정규화
- 서비스 시스템 설계 , 서버 구축

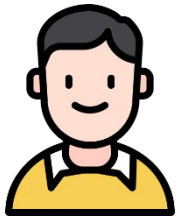

이다원
- Albert, roberta,distillbert 등 모델 학습 , 성능 비교
- 앙상블 사용 성능 향상
- 시각화 코드 작성

오희주
- GPT-2 모델 학습 , 성능 평가
- 하이퍼 파라미터 최적화

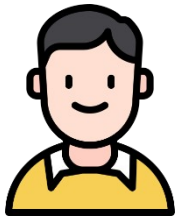

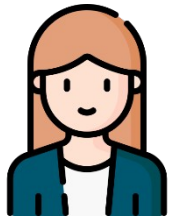

이지수
- 데이터 정제 및 정규화
- 데이터 증강 & 전처리 성과 검증

정명찬
- Electra , 등 모델 학습 , 성능 비교
- 앙상블 사용 성능 향상

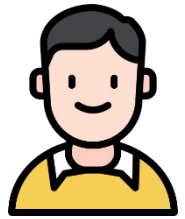

전효택
- 하이퍼파라미터 최적화
- 모델 종합 , 비교

양은지
- 하이퍼파라미터 최적화
- 모델 종합 , 비교

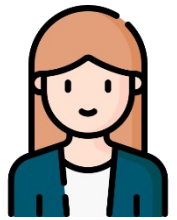

3. 진행 프로세스

프로젝트 총 개발기간 : 12/26(월) ~30(금)

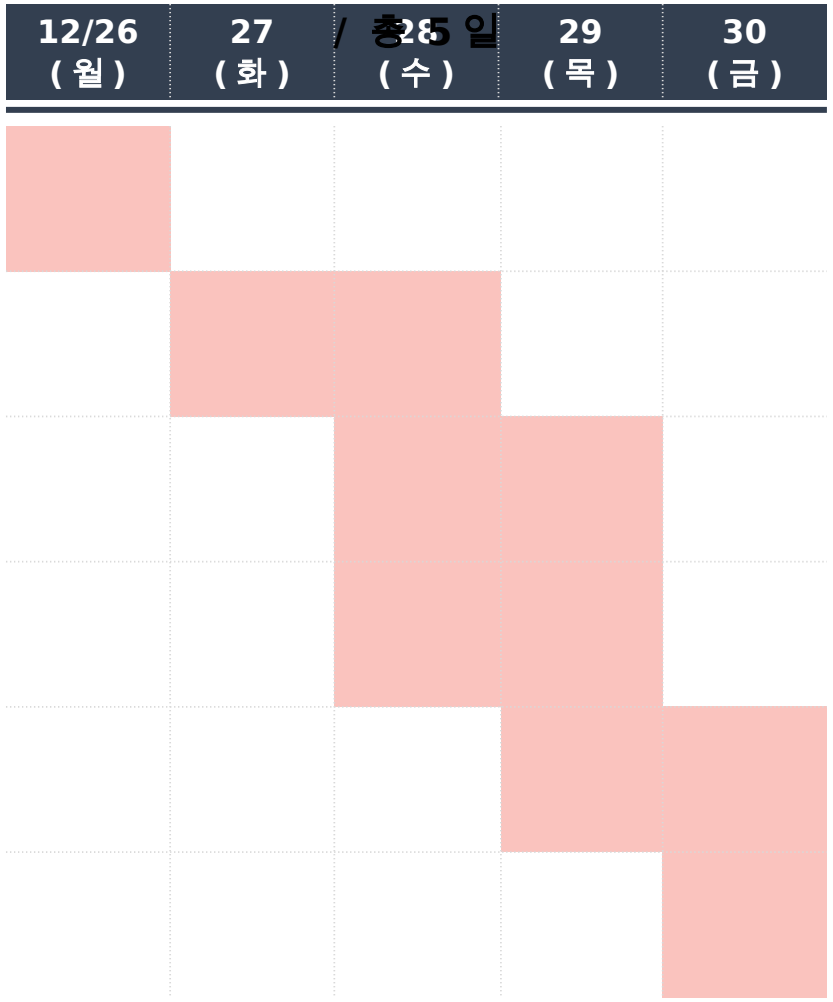

1 사전 기획
- 목표 설정 , 역할 분담 , 버그 해결

2 데이터 전처리
- 데이터 정제 , 정규화
- 데이터 증강

3 모델 선정 ,
- Pretrained Model 선정

4 최적화
: 모델 훈련 , 평가
- 하이퍼파라미터 최적화

5 모델 활용
- 앙상블 적용 최종 평가 , 서비스 시스템 설계

6 프로젝트 발표

4. 진행 결과

사전 기획

1) Baseline code 이해 (버그 수정)

- Import requirements
- Preprocess
- Pretrained Model : bert-base-uncased
- Finetuning (Training)
- Testing

- Testing 단계에서 model 을 통과해서 output 을 얻기전 collate_fn 에서 shuffle 하는 버그 발견 . 순서가 바뀌지 않도록 수정했다 .

```
#sorted_indices = np.argsort([len(input_id) for input_id in input_ids])[::-1] #bug
sorted_indices = [i for i in range(len(input_ids))]
```

2) 데이터 이해

- 영문 Yelp 식당 리뷰 데이터 셋이다 .
- Class : positive(1), negative(0)
- sentiment.dev.0 : 0 class validation data(2000 개)
- sentiment.dev.1 : 1 class validation data(2000 개)
- sentiment.train.0 : 0 class train data(177218 개)
- sentiment.train.1 : 1 class train data(266041 개)
- test_no_label.csv : no label data for submission (2000 개)

4. 진행 결과

데이터 전처리

1) Data Augmentation

neg	pos	total	neg_percent	pos_percent
177218	266041	443259	40.0	60.0

- 데이터 클래스 불균형
- **Contextual Word Embeddings Augmenter** 활용

예시 : **Original: The quick brown fox jumps over the lazy dog .**

Augmented Text:

1) the old quick brown fox instinctively jumps over for the lazy dog.

2) the quick young brown fox dog jumps over the remaining lazy dog.

- **Neg * 3 = 531654** 개
- **Pos * 2 = 532082** 개

2) TEXT 전처리 및 토큰화

- **train, validation data** 에는 숫자를 나타내는데 사용되지만 **test data** 에는 존재하지 않는 **"_num_"** 은 공백 대체
- 영어 외 특수문자는 공백 대체

4. 진행 결과

데이터 전처리

1) Data Augmentation

neg	pos	total	neg_percent	pos_percent
177218	266041	443259	40.0	60.0

- 데이터 클래스 불균형
- **Contextual Word Embeddings Augmenter** 활용

예시 : **Original: The quick brown fox jumps over the lazy dog .**
Augmented Text:
1) the old quick brown fox instinctively jumps over for the lazy dog.
2) the quick young brown fox dog jumps over the remaining lazy dog.

- **Neg * 3 = 531654** 개
- **Pos * 2 = 532082** 개

학습 시간이 너무 길어져 활용 어려움

부분적 적용 (불균형 해소)

- **Neg : 262476**
- **Pos : 266041**

4. 진행 결과

데이터 전처리

1) Data Augmentation

- **Neg : 262476**
- **Pos : 266041**

Overfitting 발생

성능 개선 효과 없음

기존의 데이터셋 활용

2) TEXT 전처리 및 토큰화

- “_num_” 은 공백 대체
- 영어 외 특수문자는 공백 대체

4. 진행 결과

모델 선정 ,

구조가 다른 다양한 모델을 통해 정확도를 확인

‘bert-base-uncased’
가장 많은 다운로드 수

‘VictorSanh/Roberta-base-finetuned-yelp-polarity’
(yelp polarity) dataset 으로 pretrained 된 Roberta 모델

‘google/electra-base-discriminator’
빠른 학습이 가능한 electra

4. 진행 결과

모델 선정 ,

구조가 다른 다양한 모델을 통해 정확도를 확인

‘bert-base-uncased’

‘VictorSanh/Roberta-base-finetuned-yelp-polarity’

‘google/electra-base-discriminator’

각 모델 테스트 결과 **98.2% ~ 98.9%** 성능 확인

4. 진행 결과

모델 선정 ,

Iteration 에 따른 accuracy 와 valid_loss 값을 확인했습니다 .

1 epoch 당 10 번의 time step 에서 Valid_loss 가 역대 최솟값인 Lowest_valid_loss 보다 낮을때 모델의 가중치를 save 합니다 .

대부분의 모델에서 1~2 epoch 내로 최적의 모델이 결정되었습니다 .

```
            #                 position_ids=position_ids,
            #                 labels=labels)
            output = model(input_ids=input_ids,
                           attention_mask=attention_mask,
                           token_type_ids=token_type_ids,
                           position_ids=position_ids,
                           labels=labels)

            logits = output.logits
            loss = output.loss
            valid_losses.append(loss.item())

            batch_predictions = [0 if example[0] > example[1] else 1 for example in logits]
            batch_labels = [int(example) for example in labels]

            predictions += batch_predictions
            target_labels += batch_labels

    acc = compute_acc(predictions, target_labels)
    valid_loss = sum(valid_losses) / len(valid_losses)

    ### matplotlib start ###

    iter_x.append(iteration)
    acc_y.append(acc)
    loss_y.append(valid_loss)

    ### matplotlib end ###


    if lowest_valid_loss > valid_loss:
        print('Acc for model which have lower valid loss: ', acc)
        torch.save(model.state_dict(), "./pytorch_model.bin")
        lowest_valid_loss = valid_loss
```

4. 진행 결과

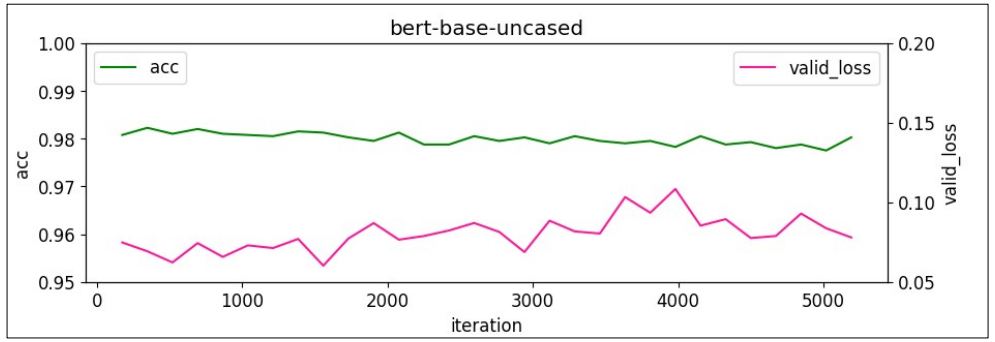

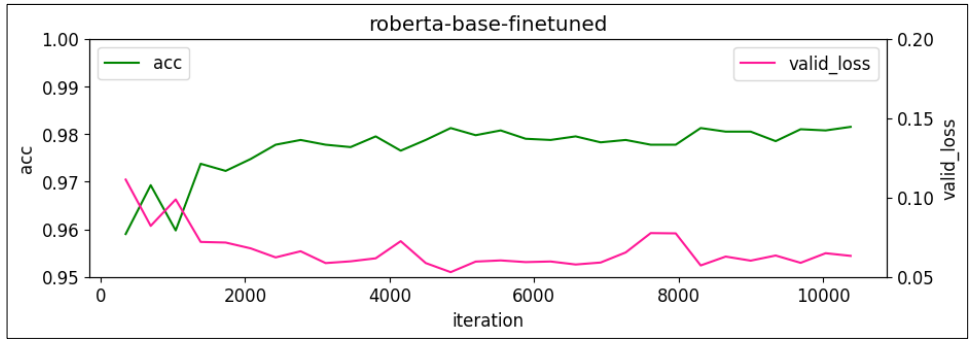

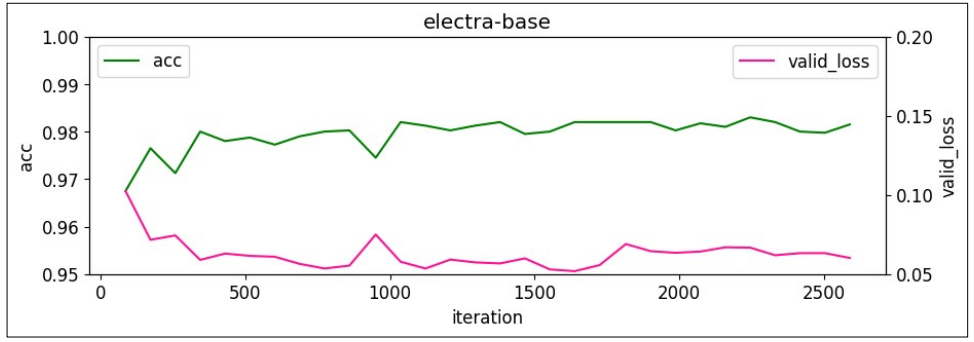


```
cnt = 0
for i in range(len(iter_x)):
    if cnt >= iter_x[i]:
        iter_x[i] = max_iteration + iter_x[i]
    cnt = iter_x[i]
cnt = 0
for i in range(len(iter_x)):
    if cnt >= iter_x[i]:
        iter_x[i] = max_iteration + iter_x[i]
    cnt = iter_x[i]
print(iter_x)
```

```
plt.style.use('default')
plt.rcParams['figure.figsize'] = (10, 3)
plt.rcParams['font.size'] = 12

x = iter_x
y1 = acc_y
y2 = loss_y

fig, ax1 = plt.subplots()
ax1.set_xlabel('iteration')
ax1.set_ylabel('acc')
ax1.plot(x, y1, color='green',label='acc')
ax1.legend(loc='upper left')
ax1.set_ylim([0.950,1])

ax2 = ax1.twinx()
ax2.set_ylabel('valid_loss')
ax2.plot(x, y2, color='deeppink',label='valid_loss')
ax2.legend(loc='upper right')
ax2.set_ylim([0.05,0.2])

plt.title("roberta-yelp-finetuned")

plt.show()
```

4. 진행 결과

하이퍼파라미터 최적화

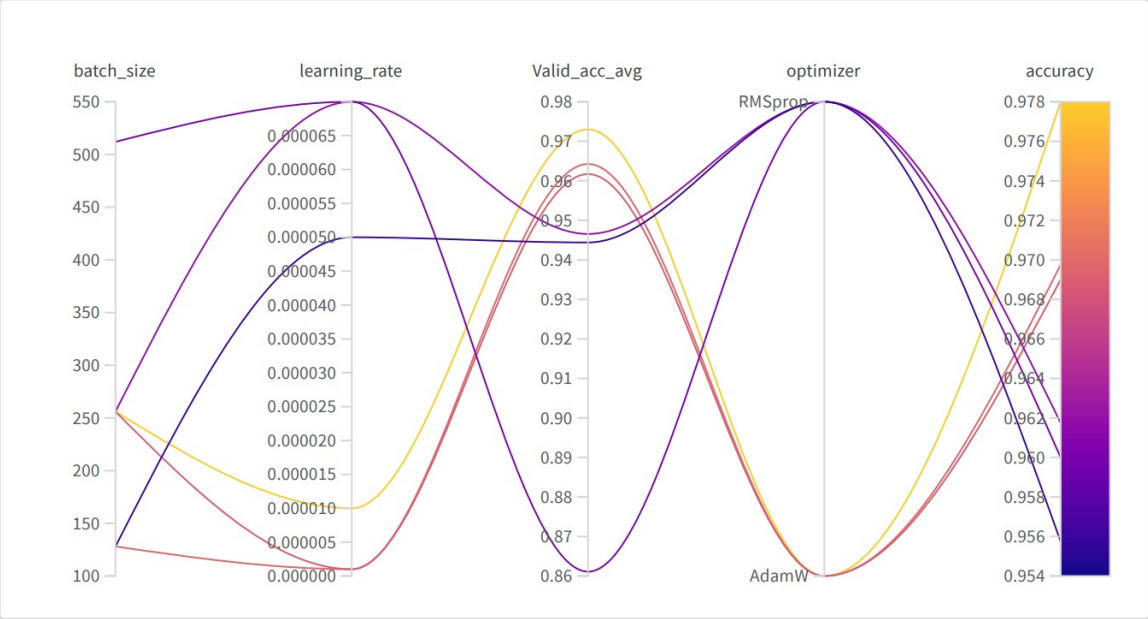

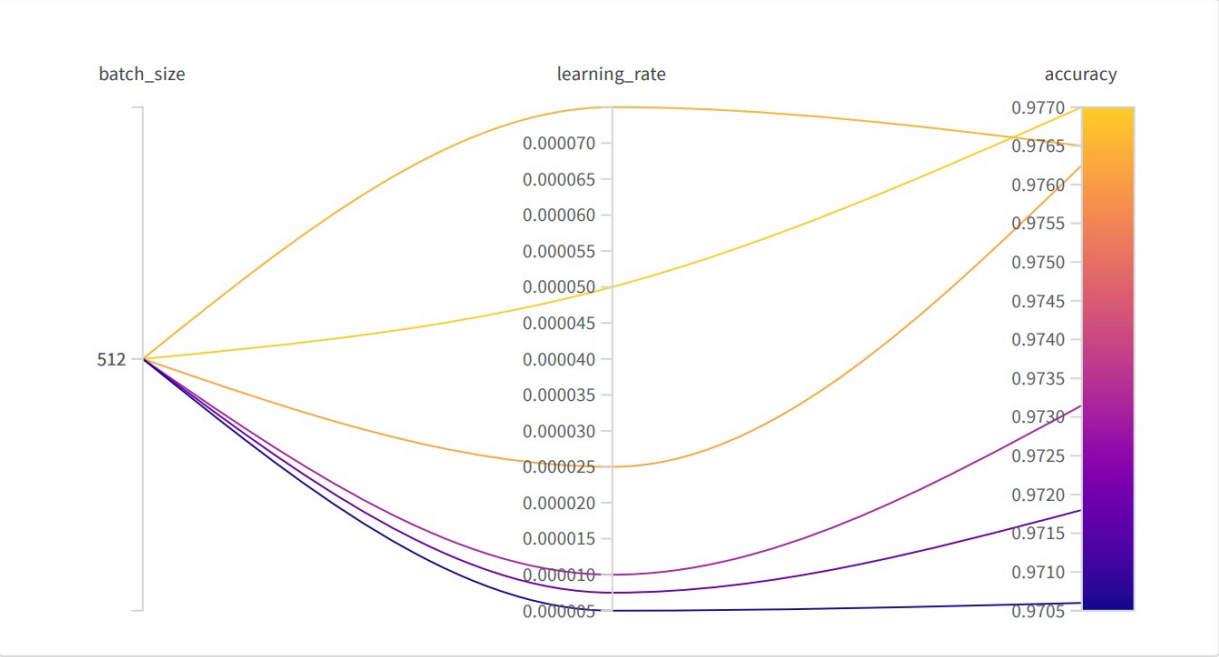

Optimizer:

AdamW

LR : 5e-5 ~ 7e-5

4. 진행 결과

하이퍼파라미터 최적화

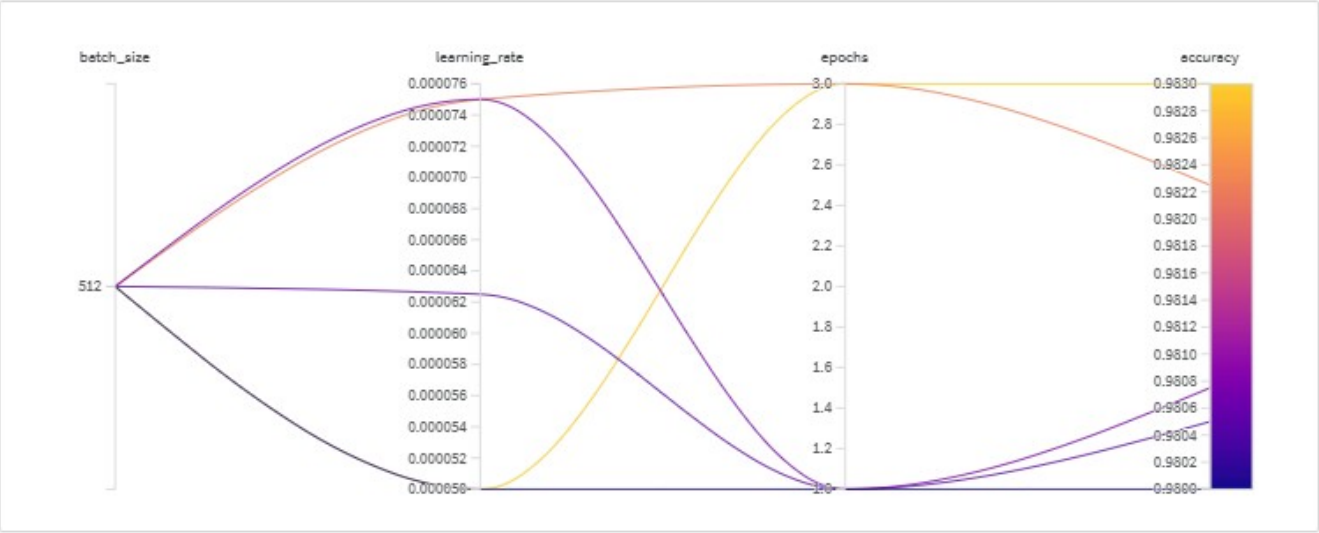

Optimizer: AdamW

Batch-size: [32, 64, 128, 256, 512] 중 가장 큰 512

Epoch: 3 (epoch 을 늘려도 training loss 크게 변동 없을 때 학습 종료)

LR: 5e-5 주변 값에서 scheduler 이용

4. 진행 결과

하이퍼파라미터 최적화

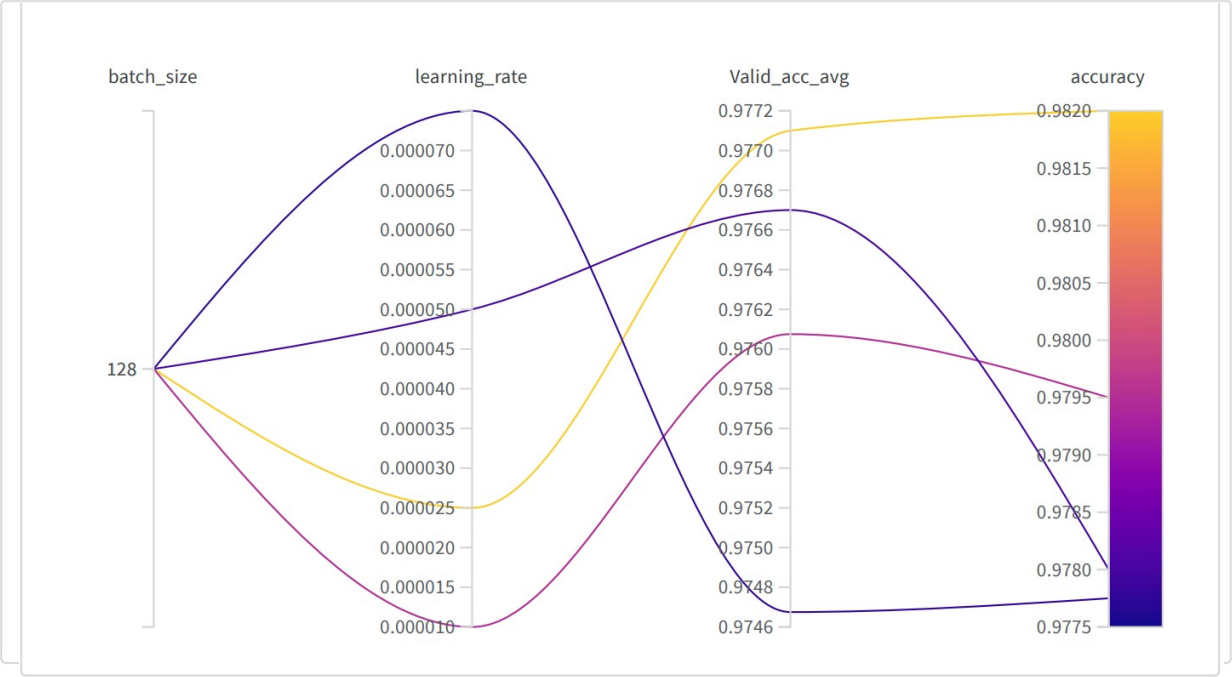

RoBERTa

Optimizer: AdamW

Batch-size: 128 (OOM 문제로 제한)

Epoch: 2

LR: 2.5e-5

4. 진행 결과

하이퍼파라미터 최적화

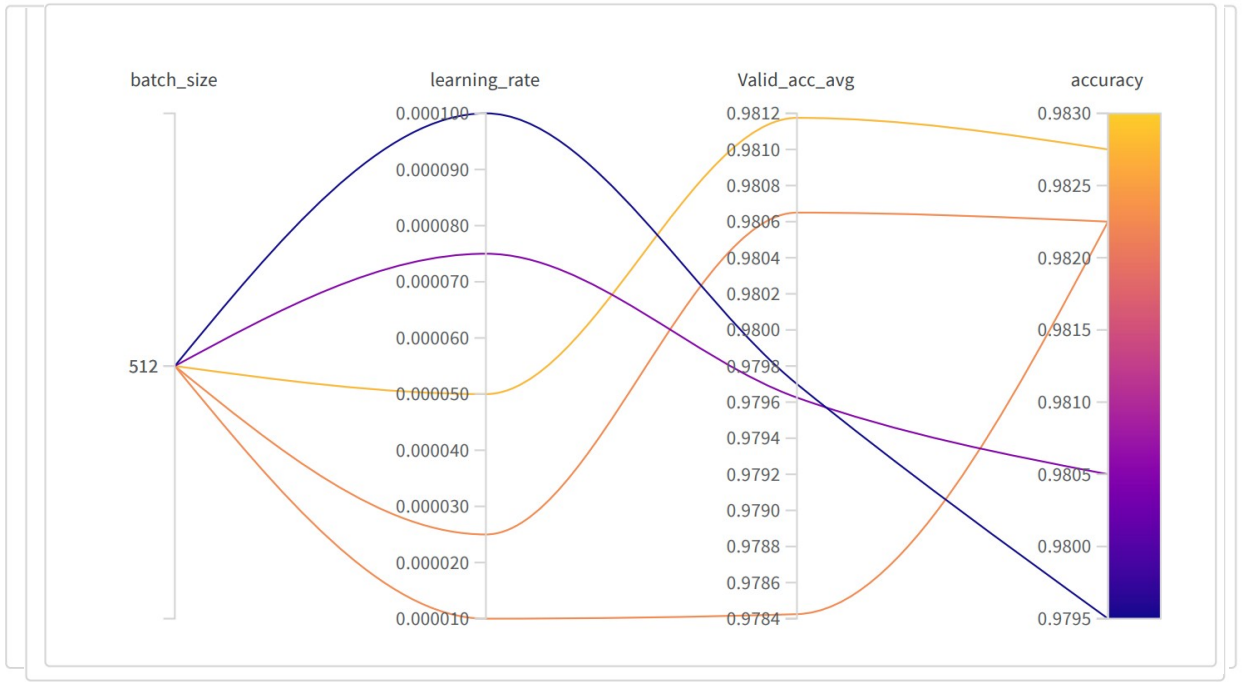

ELECTR

A

Optimizer: AdamW

Batch-size: 512

Epoch: 2

LR: 5e-5

4. 진행 결과

앙상블 – Hard

Hard Voting 기법

3 개 모델의 예측값 0, 1 중 더 많이 나온 값을 최종 예측값으로 채택

테스트 결과 99% 성능 달성

```
[ ]  pred_df = pd.DataFrame({'pred1':pred1, 'pred2':pred2, 'pred3':pred3})
```

```
def find_most_frequent(row):
    counts = row.value_counts()
    return counts.idxmax()

# Apply the function to the DataFrame and store the result in a new column
pred_df['most_frequent'] = pred_df.apply(find_most_frequent, axis=1)

print(pred_df)
```

```
     pred1  pred2  pred3  most_frequent
0        1      1      1              1
1        0      0      0              0
2        1      1      1              1
3        0      0      0              0
4        1      1      1              1
..     ...    ...    ...            ...
995      1      1      1              1
996      1      1      1              1
997      0      0      0              0
998      0      0      0              0
999      0      0      0              0

[1000 rows x 4 columns]
```

GNLP

Home About Services Method Result

ABOUT

Yelp 식당 리뷰 데이터를 활용한 문장 분류기 성능 개선 프로젝트

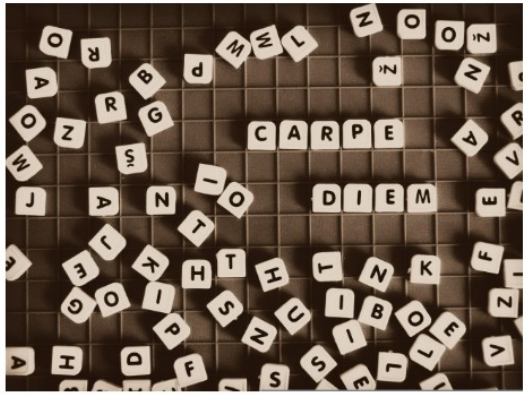

프로젝트 개요

dataset과 baseline code가 주어진 상태에서 모델의 성능을 개선 시킬 것

초기 정확도: 98.1%

목표 정확도: 99.0%

주어진 기간: 5일

최종 정확도: 99.0%

train dataset: 443259

valid dataset: 4000

식당 리뷰의 긍정/부정을 판단하는 이진분류모델의 성능 개선을 위한 여러가지 접근과 시도를 한다.

이를 통해 개발 전반적인 과정을 학습하고, 다양한 성능 향상 방법을 익히는 것을 목적으로 한다.

COLLABORATION TOOLS

slack GitHub zoom

5. 자체 평가 및 보완

- 평가 결과 , 초기 목표였던 정확도 99% 의 성능 달성
- 각 모델에 최적화된 전처리를 통해 전처리 효과 개선 필요
- 다양성을 부여한 점에서 효과가 있었으나 , 모든 모델의 구조를 완벽히 이해하지는 못하고 이용한 점 보완 필요
- 하이퍼파라미터 최적화 도구 (Wandb 등) 에 관한 이해도를 높여 다음 프로젝트에 더욱 다양한 시도 기대
- 웹 서비스화 할 수 있도록 서버 작업 진행

첫 번째 프로젝트 : Yelp 식당 리뷰 데이터 를 활용한 문장 분류기 성능 개선

2 조 . 김도연 , 양은지 , 오희주 , 이다원 , 이지수 , 전효택 , 정명찬

감사합니다