


PROJECT 1 _ TEXT CLASSIFICATION

using BERT

Jeonhyotaek

Type '/' for commands

▼ Training 1



Import panel

Add panel



batch size : 32~512

epoch : 1~3

learning rate : $1e-4 \sim 1e-6$

Try to find hyperparameters that maximize validation accuracy.

The problem with the first attempt was that the training & validation batch size were not considered


together

The encouraging thing is that when the learning_rate is less than $1e-5$, the validation accuracy is usually high.

it would be easier to find other parameters to reduce the epoch value and apply it to various test cases.

한줄요약 : 배치사이즈를 하나를 고정으로 두고 학습 진행. 제대로 학습 X. learning_rate에 대해 유의미한 값 얻음.

▾ Training 2



Import panel

Add panel



batch size : 32~512

epoch : 1

learning rate : $1e-5 \sim 1e-6$

Before proceeding with training, I wanted to apply something else to optimizer.

Therefore, AdamW and RMSprop were put together in the test case.

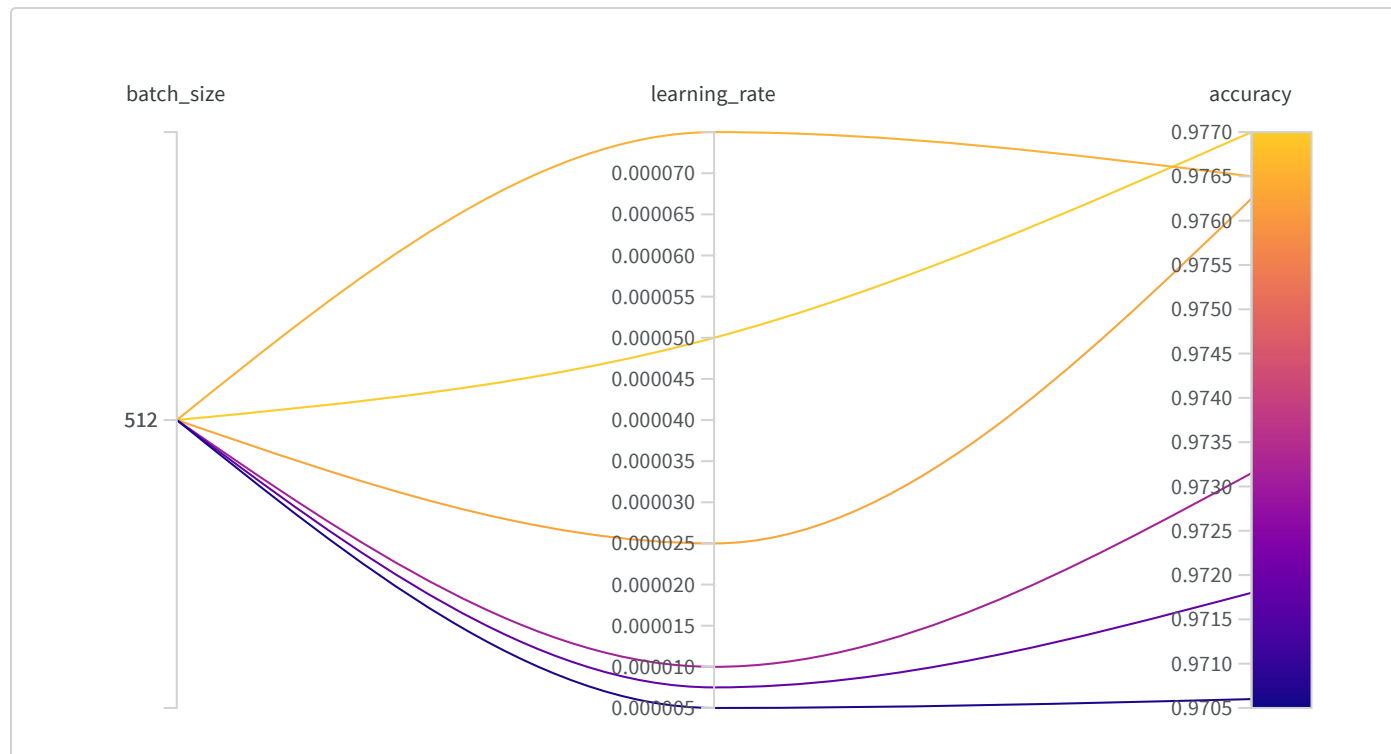
And the learning rate was designated between $1e-5$ and $1e-6$ through the result value checked above.

As a result, the difference between RMSprop and AdamW is clearly large,

so the experiment was stopped early, and AdamW will be used for next training.

한줄요약 : optimizer를 다양한 모델로 사용해보고 싶었으나 AdamW의 성능이 좋아 AdamW로 다음실험 진행.

▼ Training 3



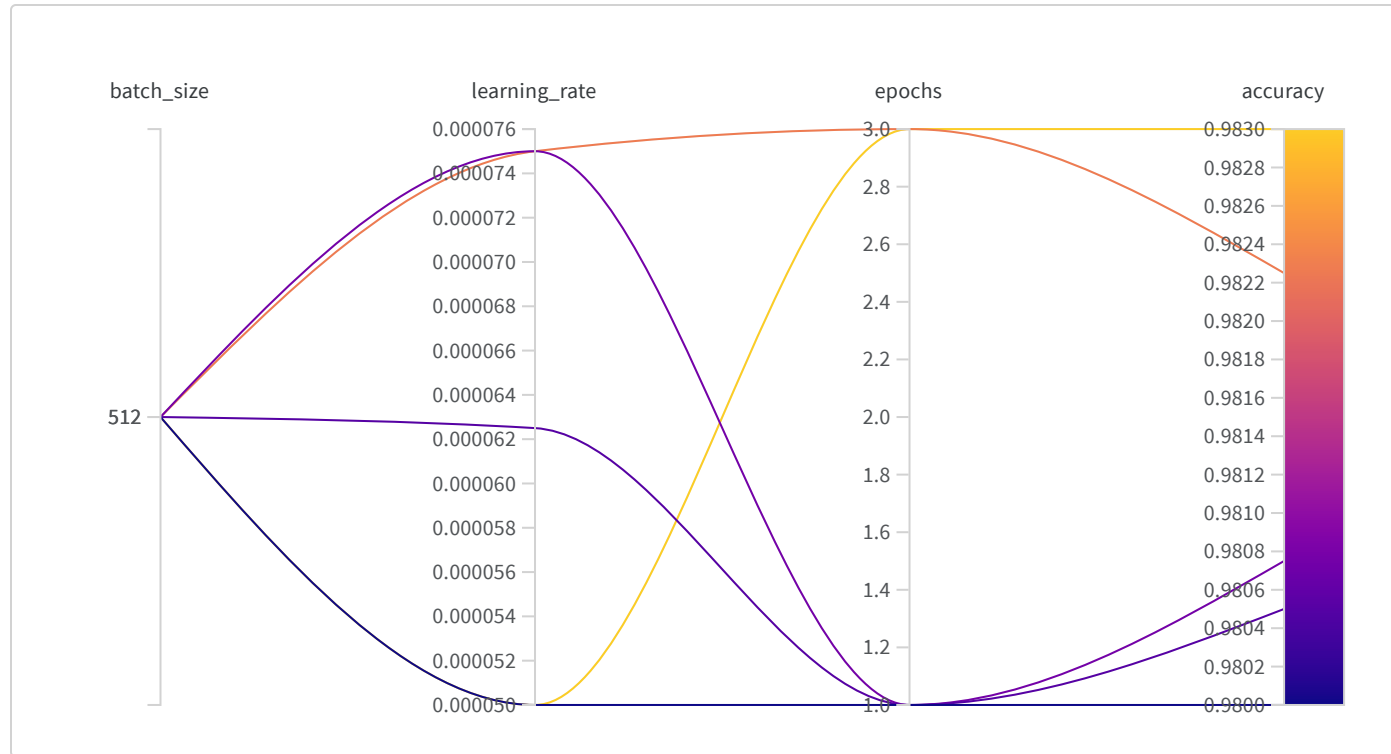
Import panel

Add panel



Training 1에서 얻은 결과값을 토대로 5자리수 이하의 learning rate 중에서 어느 범위의 learning rate가 효과적일지에 대한 판단을 위해 $1e-4 \sim 1e-6$ 범위의 learning rate의 학습을 진행한 결과 $5e-5 \sim 7.5e-5$

사이의 값이 최적의 learning_rate임을 알 수 있음.



Import panel

Add panel



validation_acc



? \mathcal{X}

Draft autosaved just now

⋮

↓

Save

Import panel

Add panel

+

- ⋮ epoch 10으로 두고 학습한 결과. 1~5까지는 유의미한 결과를 얻을 수 있으나 그 이후부터는 변화가 미비함. 다른 모델들에서도 적용했을때 대체적으로 epoch는 3~5 사이의 값으로 두는게 가장 합리적임.

▼ <hyperparameter 조정 결과>

-> learning_rate : $5e-5 \sim 7.5e-5$ // batch size에 비례해서 조절해야함. batch가 커지면 learning rate도 함께 커야하고, batch가 작으면 함께 작은 값으로 학습해야함.

-> 각 hyperparameter 튜닝 시에는 나머지 값들 전부 통일 시켜둔 뒤에 진행.

-> (1) **optimizer** : AdamW가 가장 높은 성능

: optimizer 세부 조정 (weight decay, eps) 설정 [0.9727]

(1-1) 미세조정 **weight decay** $1e-4 \sim 1e-7$ ($1e-6$), **eps** $1e-2 \sim 1e-4$ ($1e-2$) ; weight decay는 $1e-6$, eps는 $1e-2$ 에서 가장 높은 성능을 보임.

(1-2) weight decay $1e-6$ / eps $1e-2$ 에서 조금씩 조정.

(1-3) 추가적인 optimizer = BERTAdam으로 진행 했을때 큰 차이 없음.

-> (2) **batch_size** 최대 조정 (train 256 / valid 512) [0.9770] (batch_size는 최대로)

: batch_size : [32,64,128,256,512] 중 최대 batch_size가 가장 높은 성능을 보임.

(2-1) train = valid batch_size [0.9760] <-> train 128 valid 512 [0.9769]; 유의미한 차이는 없음.

(2-2) batch size = 1000으로 지정했을 때는 큰 차이 없음.

-> (3) **epoch** 1,3 값 진행. (epoch을 늘려도 lr 값에 대한 순위 변동이 있는지 확인 -> epoch 3 이후의 training loss 추적하며 판단. 값이 계속수렴하여 변동이 크게 없을 때는 학습 종료. ~>)

: epoch 값이 3까지 커질 때 당연하게도 성능이 높아지지만 5 이상의 값들에 대해서는 유의미한 향상을 볼 수 없었음.

-> (4) Learning rate : 5e-5 주변의 learning rate값이 성능이 높았고, learning rate scheduler를 사용해서 성능을 평가해봄

: LambdaLR, StepLR, 등을 사용해 보았을 때 성능이 초반에는 큰 영향이 없다가 후반부의 loss 값들이 떨어지는것을 확인할 수 있었음. learning rate scheduler를 사용하여 epoch마다 lr값 수정하도록 적용.

[결론] : hyperparameter를 다방면으로 조절해가며 loss와 acc값을 확인해보았는데 batch_size 이외에는 유의미한 결과값을 얻지 못했다. 성능을 높이기 위해 다른 모델들도 검토하는 방향으로 실험을 설계했다. 모델 성능이 크게 이상없는한 train 과정에 포함시켜 voting 기법을 적용해 학습 정확도를 높이는 방향으로 진행한다.

▾ Different type of BERT Models

▾ albert-base-v2

기본 코드 accuracy : Acc for model which have lower valid loss: 0.97775

lr scheduler / batch_size 조정 후 learning_rate \leftrightarrow accuracy 결과 $1e-5$ 최대값. (이외의 값들 더 해봤으나 의미없는 값으로 나와 제거.)



Import panel


Add panel



▼ Electra

기본 코드 accuracy : Acc for model which have lower valid loss: 0.9820

lr scheduler / batch_size 조정 후 learning_rate <-> accuracy 결과 5e-5 최대값.



Import panel


Add panel



▼ RoBERTa

기본 코드 accuracy : Acc for model which have lower valid loss: 9810

lr scheduler / batch_size 조정 후 learning_rate <-> accuracy 결과



Import panel

Add panel



